

"Listening In": Social Signal Detection for Crisis Prediction

۱ مسئله اصلی چیست و چرا مهم است؟

مقاله روی این مسئله تمرکز دارد که بحران‌ها معمولاً سیگنال‌های هشدار اولیه تولید می‌کنند؛ اما این سیگنال‌ها اغلب ضعیف هستند و در نویز زندگی روزمره گم می‌شوند. در مدیریت بحران، اگر بتوان این سیگنال‌های اولیه را زودتر تشخیص داد، سازمان‌ها می‌توانند پیش‌دستانه آماده شوند و قبل از وقوع بحران واکنش‌های مناسب دهند. در عین حال، تشخیص سیگنال از توییت‌ها در عمل رایج نشده چون حجم نویز و توییت‌های نامرتبط بالاست و همچنین مشکلاتی مثل سوگیری زبانی/فرهنگی و کمبود کانتکست به‌خاطر کوتاه بودن توییت‌ها وجود دارد. ایده این مقاله این است که با یک روش Open-domain و چندزبانه، بتوان توییت‌ها را به‌صورت موثر پالایش کرد تا تنها بخش مرتبط با بحران باقی بماند و سپس با تحلیل روند (Burst/Trend) رشدهای غیرعادی را به‌عنوان سیگنال شناسایی کرد.

۲ ورودی‌ها و خروجی‌های مدل/سیستم چیست؟


در پیاده‌سازی مقاله، ورودی/خروجی‌ها به‌صورت زیر تعریف می‌شوند:

ورودی‌ها

- کلیدواژه‌های دامنه: (متن ساده) که کاربر برای موضوع بحران می‌دهد؛ مثال حوزه انرژی: rising و Blackout و ...
- تنظیمات اجرایی: کشور/زبان/بازه زمانی سیستم قابل تعیین است.
- داده توییت: توییت‌های زنده/تاریخی از طریق Twitter/X API.

خروجی‌ها

- توییت‌های فیلترشده و مرتبط با بحران: توییت‌هایی که informative تشخیص داده شده‌اند و احساس negative/neutral دارند.
- هشدار سیگنال: وقتی روند فراوانی توییت‌های مرتبط وارد فاز رشد پایدار شود.
- نمایش روند: در سرویس نمونه، خروجی شامل ویژوال‌سازی شبیه شکل زیر است.



(a) Crisis event e_1 : "Peak in electricity price", Germany, Jan 2020 - Dec 2022.

۳ داده مورد استفاده (نوع، منبع، اندازه) چیست؟

مقاله دو منبع داده اصلی برای کار دارد:

الف) داده برای فاین تیون مدل پالایش

- دیتاست: CrisisBench
- اندازه: 156,899 توییت
- تقسیم‌بندی: $train = 109,796$, $dev = 16,008$, $test = 31,095$
- وظیفه یادگیری: طبقه‌بندی دودویی informative در برابر not informative .

ب) داده برای ارزیابی سرویس سیگنال‌دهی

- منبع: Twitter/X از طریق API
- اندازه خام: 46,963 توییت از آلمان، بریتانیا، اسپانیا

۴ روش پیشنهادی مقاله به زبان ساده + شماتیک یا شبه‌کد

مقاله روش OSOS را معرفی می‌کند: یک pipeline سه‌مرحله‌ای که از داده توییت‌ر + کلیدواژه‌های دامنه شروع می‌کند و با هشدار سیگنال پایان می‌دهد. در توضیح مقاله، خروجی پیش‌پردازش وارد پالایش می‌شود و خروجی پالایش وارد آشکارساز سیگنال می‌گردد.

۴.۱ گام اول: پیش‌پردازش

- حذف کاراکترهای خاص، lowercase، حذف تکراری‌ها و رشته‌های خالی، حذف punctuation .
- توکنایز و جمله‌بندی و تبدیل توییت به لیست توکن‌ها.

۴.۲ گام دوم: پالایش داده

هدف: حذف نویز و نگه داشتن توییت‌هایی که واقعا به بحران مربوط‌اند.

1. طبقه‌بندی با استفاده از GPT-3 (Curie) که روی CrisisBench فاین تیون شده تا توییت‌های بحران مرتبط را بهتر تشخیص دهد.
2. تحلیل احساسات با DistilBERT و تمرکز روی negative یا neutral چون در متن اشاره می‌شود این دو احساس معمولاً با رویدادهای بحران مرتبط همراه‌اند و لذا سیستم روی آن‌ها تمرکز می‌کند.

خروجی این ماژول: مجموعه‌ای از توییت‌هایی که هم informative هستند و هم negative/neutral؛ بقیه کنار گذاشته می‌شوند.

۴.۳ گام سوم: آشکارسازی سیگنال

روش مقاله:

- فراوانی توییت‌های مرتبط فیلترشده به سری زمانی روزانه نگاشت می‌شود.
- trend component استخراج می‌شود و سپس دوره‌های رشد نمایی در روند بررسی می‌گردد.
- تعریف سیگنال: دوره‌ای از رشد نمایی که حداقل ۷ روز دوام داشته باشد و آستانه ۱۰٪ تغییر در فراوانی توییت‌ها را رد کند؛ در این صورت هشدار صادر می‌شود.

۵ نتایج اصلی، محدودیت‌ها و ایده‌های ادامه

۵.۱ نتایج اصلی

الف) کیفیت ماژول پالایش

در ارزیابی چند مدل روی CrisisBench، مدل GPT-3FT (Curie) بهترین عملکرد را گزارش می‌کند: $F1 = 0.905$ و $Accuracy = 0.882$ بهتر از گزینه‌های دیگر.

ب) عملکرد سرویس در اجرا

- از 46,963 توییت خام، پس از پیش‌پردازش و پالایش، 7042 توییت برای تحلیل نهایی باقی مانده است.
- سرویس سیگنال‌دهی برای سه رویداد انرژی‌مرتبط تاریخی بررسی شده و معیار تصمیم تغییر فراوانی توییت‌ها (FC%) در بازه‌های 12، 8 و 4 هفته قبل از رخداد گزارش شده است.

۵.۲ محدودیت‌ها

مقاله چند محدودیت/ریسک کلیدی را صریح بیان می‌کند:

1. روش نشان نمی‌دهد همه انواع بحران با یک سطح عملکرد قابل پیش‌بینی‌اند؛ تمرکز روی بحران‌های قابل پیش‌بینی اما به‌سختی قابل کنترل بوده (مثل افزایش قیمت انرژی).
2. تکیه اصلی روی داده‌های توییت‌ر است و در نتیجه با مسئله کیفیت پایین، اطلاعات غلط و توییت‌های جعلی مواجه می‌شود؛ حتی امکان دست‌کاری با ارسال انبوه توییت‌های مخرب وجود دارد.
3. درباره یکی از رویدادهای تاریخی‌مذکور اشاره می‌کند که تغییرات کوچک‌تر بوده و می‌تواند ناشی از مسائل آستانه ۷ روزه یا عوامل ارتباطی در ادراک بحران باشد و این موضوع خودش یک پرسش پژوهشی می‌سازد.

۵.۳ ایده‌های ادامه

- افزودن تکنیک‌های راستی‌آزمایی برای کاهش اثر اطلاعات غلط.
- ترکیب OSOS با منابع اطلاعاتی دیگر (مثلا اخبار، داده‌های بازار، گزارش‌های کسب‌وکار) برای مقاوم شدن و کاهش ریسک‌های توییترمحور بودن.